

Desplaçament polític per llengua en models de llenguatge

Com varia el posicionament dels LLM en català i castellà, ancorat al CEO i al CIS

Xavier Vinaixa Roselló

Sorensen AI, Barcelona, Catalunya · xavi@sorensen.ai · ORCID 0009-0005-2769-9215

Juny de 2026 · Preprint v0.1 · DOI: [10.13140/RG.2.2.22319.70561](https://doi.org/10.13140/RG.2.2.22319.70561)

Resum. No preguntem si un model és *d'esquerreres o de dretes*, sinó una qüestió més estreta i falsable: **canvia la distribució de respostes d'un model a preguntes d'enquesta reals segons si se'l consulta en català o en castellà**, i com de lluny està de la població humana? Mesurem el **desplaçament translingüe** —la divergència de Jensen–Shannon entre la resposta catalana i la castellana al mateix ítem— sobre 21 ítems amb distribució poblacional real del **CEO** (Catalunya) i el **CIS** (Espanya), en 10 models de cinc proveïdors (Google, Anthropic, OpenAI, Meta/Llama via Groq i DeepSeek). El mètode adapta el de MENAValues; la contribució principal és mesurar aquest desplaçament en català i castellà, ancorat a les poblacions que els parlen. Quatre troballes: (i) **els dos Gemini es desplacen molt més** que la resta (0.556 i 0.534, enfront de 0.164–0.383); (ii) com que la JSD amb ~60 mostres té un **soroll de fons** positiu, en restar-lo el panell s'estratifica: Gemini té desplaçament *net* alt (0.32–0.38), Claude i Llama moderat (~0.20), i **gpt-oss i gpt-5.4-mini queden baixos (~0.10)**; el seu desplaçament és en bona part soroll; (iii) **deepseek-v4-flash és el més estable de tots**: el seu desplaçament cru (0.164) és pràcticament tot soroll de fons i el net cau a $0.037 \approx 0$; (iv) **els ítems d'identitat, independència i confiança institucional** són els que més ballen per llengua, mentre que l'economia i la ideologia esquerra–dreta són els més estables. L'alineació amb la població és moderada en tots els models i *no* s'ha de llegir com un rànquing moral.

1 La pregunta

La literatura recent ha mostrat, en diversos grups i famílies lingüístiques, que **la llengua de la indicació mou el posicionament polític elicitat** d'un LLM [4, 5, 6]. La crítica de Röttger et al. [2] desaconsella el Political Compass: el resultat depèn del format i de la redacció. Per això abandonem l'eix abstracte i fem una pregunta ancorada:

Donat el mateix ítem d'enquesta, la mateixa població i dues llengües, quant es mou la distribució de respostes del model, un cop descomptat el soroll de mostreig?

El català és pràcticament absent d'aquesta literatura; el castellà hi apareix com una llengua més. Posar el català i el castellà al centre, ancorats a les poblacions que els parlen (CEO, CIS), és la contribució.

2 Mètode

Veritat de referència. 21 ítems amb la distribució marginal real de població: la majoria del **CEO** (Baròmetre d'Opinió Política; independència, identitat, ideologia, monarquia, model d'estat i una àmplia bateria de confiança institucional —governos, parlaments, partits, tribunals, policia, exèrcit, sindicats, etc.) i dos del **CIS** (situació econòmica i ideologia esquerra–dreta). Cada ítem porta la seva onada exacta, la URL de la font i la data d'accés; només distribuïm *marginals agregats*, mai microdades.

Mètode (adaptat de MENAValues [1]). Per a cada ítem es compara la distribució de respostes del model amb la de la població, creuant tres *enquadraments de perspectiva* (neutral, personalitzat, observador) amb les llengües català i castellà. La distribució del model s'estima per mostreig (els proveïdors tancats no exposen logprobs).

Mètriques. El titular és el **desplaçament translingüe**, la divergència de Jensen–Shannon mitjana entre les respostes en català i en castellà al mateix ítem (1 = màxim desplaçament). Com que la JSD amb mostres finites té un **biaix positiu**, estimem per a cada ítem un *soroll de fons* (la JSD esperada entre dues mostres de la mateixa distribució) i reportem el **desplaçament net** = cru – fons, amb un interval de confiança de remostreig (bootstrap) *jeràrquic* (remostreja ítems i, dins de cada ítem, les mostres). Per als ítems d'escala ordinal (confiança i ideologia, 0–10) afegim la **distància de Wasserstein-1 (EMD)**, que —a diferència de la JSD, nominal— cobra per la distància recorreguda. L'alineació amb el CEO/CIS (1 – JSD model–població) es reporta com a context.

Rigor. (a) *Robustesa de plantilles* [2]: cada enquadrament es prova amb 3 paràfrasis i es reporta la desviació entre plantilles. (b) *Fallades explícites*: una resposta on cap mostra s'analitza es marca invàlida i s'*exclou*, mai s'emmascara com a distribució uniforme. (c) *Equivalència de traducció*: un jutge LLM confirma que les versions catalana i castellana de cada ítem són equivalents, i el rànquing de desplaçament no canvia si s'exclou l'únic ítem marcat —el desplaçament **no és un artefacte de traducció**. (d) *Control de rebuig*: com que menys mostres vàlides inflen la JSD, recalculem el desplaçament igualant la *n* vàlida efectiva de tots els models al mínim comú.

3 Resultats

Els Gemini es desplacen molt més (Fig. 1). Els dos models de Google (**0.556 i 0.534**) encapçalen amb diferència; la resta va de 0.164 a 0.383. Per darrere hi ha els dos Claude (0.383 i 0.381), els dos Llama (0.342 i 0.318), els dos gpt-oss (0.315 i 0.311), gpt-5.4-mini (0.236) i, l'últim, deepseek-v4-flash (0.164).

El soroll de fons reordena el bloc del mig. Amb ~60 mostres sobre ítems d'11–13 categories, una part del desplaçament cru és soroll. En restar el fons,

Taula 1: Desplaçament translingüe cru i **net** (cru – soroll de fons), alineació, rebuig i robustesa, per model (10 models, 21 ítems, 126 respostes per model). Ordenat per desplaçament cru.

Model	Desplaç.	[IC 95%]	Net	Alineació	Rebuig	SD plant.
gemin-3.1-flash-lite	0.556	[0.50, 0.62]	0.383	0.239	4.6 %	0.059
gemin-3.5-flash	0.534	[0.48, 0.59]	0.318	0.285	9.4 %	0.066
claude-sonnet-4-6	0.383	[0.32, 0.44]	0.258	0.271	0.0 %	0.049
claude-opus-4-8	0.381	[0.33, 0.43]	0.230	0.247	0.4 %	0.048
llama-3.3-70b	0.342	[0.29, 0.39]	0.200	0.291	0.0 %	0.045
llama-4-scout-17b	0.318	[0.26, 0.38]	0.196	0.347	0.0 %	0.036
gpt-oss-20b	0.315	[0.29, 0.35]	0.108	0.383	6.2 %	0.055
gpt-oss-120b	0.311	[0.29, 0.34]	0.109	0.337	5.7 %	0.049
gpt-5.4-mini	0.236	[0.20, 0.27]	0.091	0.307	0.0 %	0.046
deepseek-v4-flash	0.164	[0.14, 0.19]	0.037	0.267	0.0 %	0.037

el desplaçament *net* estratifica el panell: Gemini segueix alt (0.383 i 0.318); Claude i Llama queden moderats (~ 0.20 – 0.26); i **gpt-oss i gpt-5.4-mini cauen a ~ 0.09 – 0.11** , és a dir, el seu desplaçament aparent és en bona part soroll de mostreig, no un efecte real de la llengua.

DeepSeek és el més estable (Fig. 1). El desplaçament cru de deepseek-v4-flash (0.164) és gairebé idèntic al seu soroll de fons, de manera que el net cau a $0.037 \approx 0$: respon pràcticament igual en català i en castellà. És l’únic model el desplaçament del qual queda explicat del tot pel soroll.

Identitat i confiança, no economia (Fig. 2). Els ítems que més ballen per llengua són la independència, la confiança en institucions (Govern d’Espanya, Església, partits, Govern de Catalunya), la monarquia i la identitat nacional. Els *més estables* són la situació econòmica i la ideologia esquerra-dreta. La mètrica ordinal (EMD, Fig. 3) ho confirma per a les escales 0–10: els Gemini hi mouen més massa, i en distància, que la resta.

El rebuig és baix i no explica el desplaçament (Fig. 4). El rebuig màxim és de gemini-3.5-flash (9.4 %), seguit de gpt-oss-20b (6.2 %), gpt-oss-120b (5.7 %) i gemini-3.1-flash-lite (4.6 %); la resta rebutja poc o gens. Com que menys mostres vàlides poden inflar la JSD, igualem la *n* vàlida efectiva de tots els models al mínim comú: el rànquing es manté i la distància dels Gemini respecte de la resta es conserva. El doble desplaçament dels Gemini **no és un artefacte del rebuig**.

4 Conclusions

1. **El desplaçament per llengua és real, però cal descomptar el soroll.** El desplaçament cru va de 0.164 a 0.556; el net, de ≈ 0 a 0.383. Reportar només el cru sobreestima els models del mig. Per a qualsevol desplegament bilingüe (atenció ciutadana, educació, mitjans), el desplaçament net és el risc operatiu rellevant.
2. **Gemini és un cas a part:** és el que més es desplaça en cru, en net i en la mètrica ordinal, i —en el cas de gemini-3.5-flash— també el que més rebutja. L’efecte aguanta en igualar la *n* vàlida.

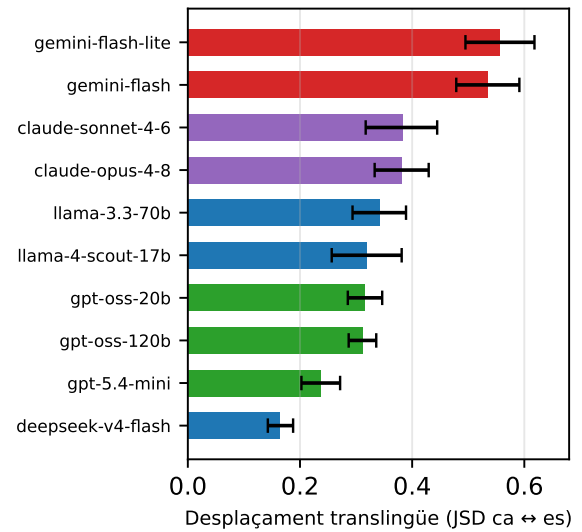


Figura 1: Desplaçament translingüe per model (JSD català ↔ castellà), amb interval de confiança de remostreig (bootstrap) al 95 %. Vermell: Gemini; lila: Claude; verd: GPT (oss i 5.4-mini); blau: Llama i DeepSeek.

3. **DeepSeek és el més consistent:** el seu desplaçament queda explicat pel soroll (net ≈ 0). Mostra que un desplaçament baix i estable per llengua és assolible.
4. **El desplaçament es concentra en l’eix nacional i de confiança institucional,** no en l’economia ni la ideologia: la llengua de la indicació activa respostes diferents allà on el conflicte català-espanyol és més viu.
5. **Això no és un rànquing moral.** Mesurem representativitat i estabilitat lingüística, no “biaix” normatiu: sota l’enquadrament observador, una alineació alta és en part predir la població, no tenir-hi una opinió.

5 Limitacions

Conjunt encara petit (21 ítems); els números tenen data d’una onada concreta. Dual-referència (mateixa pregunta a les dues poblacions) limitada a la ideologia,

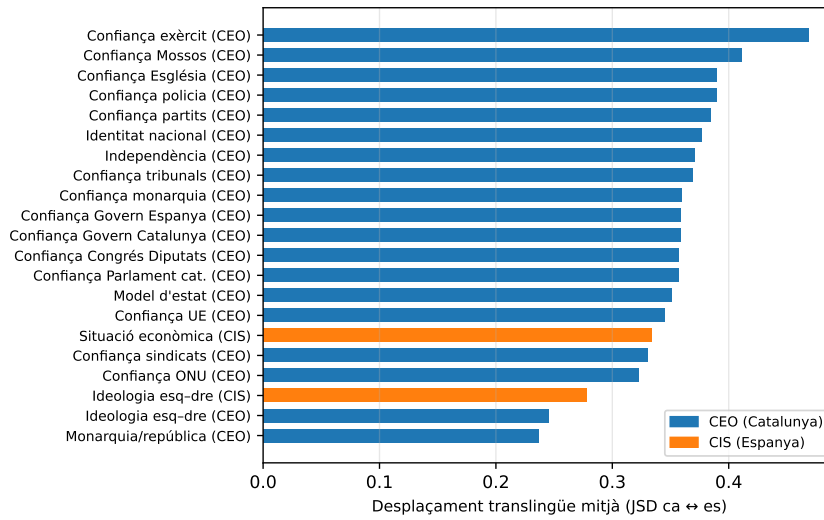


Figura 2: Desplaçament translingüe mitjà entre models, per ítem d'enquesta. Les qüestions d'identitat, independència i confiança institucional encapçalen; l'economia i la ideologia són les més estables.

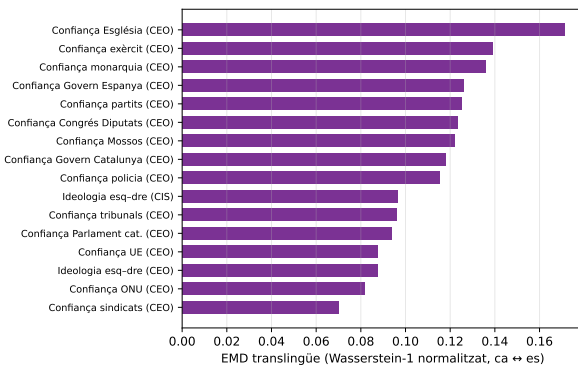


Figura 3: Mètrica ordinal (Wasserstein-1 normalitzat) per als ítems d'escala 0–10 (confiança i ideologia): cobra per la distància recorreguda, no només pel canvi de categoria.

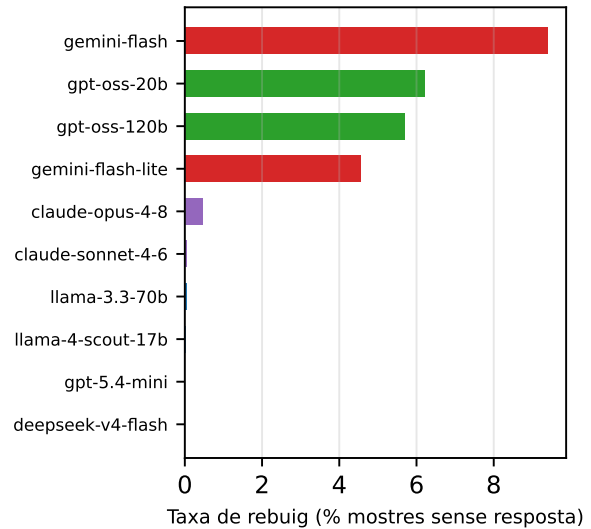


Figura 4: Taxa de rebuig per model (percentatge de mostres sense resposta vàlida, majoritàriament descàrrecs de neutralitat en preguntes polítiques sensibles).

perquè el baròmetre mensual del CIS comparteix poc amb el CEO; explotar-la per a un test direccional és preliminar i una via de futur. El mostreig no veu la massa interna del model (“logit leakage”), només disponible en proveïdors amb logprobs. El panell reportat són els 10 models de la Taula 1.

Referències

- [1] Zahraei, P. S., & Asgari, E. (2025). *I Am Aligned, But With Whom? MENA Values Benchmark for Evaluating Cultural Alignment and Multilingual Bias in LLMs*. arXiv:2510.13154.
- [2] Röttger, P., et al. (2024). *Political Compass or Spinning Arrow? Towards More Meaningful Evaluations for Values and Opinions in LLMs*. ACL.
- [3] Feng, S., et al. (2023). *From Pretraining Data to Language Models to Downstream Tasks: Tracking the Trails of Political Biases*. ACL.
- [4] *Bias Beyond Borders: Political Ideology Evaluation and Steering in Multilingual LLMs* (2026). arXiv:2601.23001.

[5] *Multilingual Political Views of LLMs: Identification and Steering* (2025). arXiv:2507.22623.

[6] *Do Political Opinions Transfer Between Western Languages?* (2025). arXiv:2508.05553.

Dades: CEO (Generalitat de Catalunya) i CIS (Govern d'Espanya). Codi i dades: github.com/xaviviro/llm-political-alignment-ca-es.